

EVOLVERH

Sistema Inteligente de RH com IA Generativa

Repositório EvolveRH

Cauê Marinho Gomes – cmgs3

Jorge Freitas - jlcf

Karen Verçosa – kvv

Maria Beatriz Martins -mbmpg

Recife, 09 de Dezembro de 2025

[Prof. Vinicius Cardoso Garcia \(vcg@cin.ufpe.br\)](#)

Sumário

Sistema Inteligente de RH com IA Generativa.....	1
1. Introdução.....	4
1.1 Contextualização do Problema.....	4
1.2 Objetivos do Projeto.....	5
Objetivo Geral:.....	5
Objetivos Específicos:.....	5
1.3 Justificativa Tecnológica e Abordagem Metodológica.....	5
• Fase de Imersão:.....	6
• Fase de Ideação:.....	6
• Fase de Produção:.....	6
• Fase de Validação:.....	6
2. Metodologia.....	6
2.1 Fases do Desenvolvimento.....	6
1. Imersão.....	7
2. Ideação.....	7
3. Produção.....	8
4. Validação.....	8
2.2 Gestão do Projeto.....	9
1. Organização em marcos principais:.....	9
2. Controle de versão e colaboração:.....	9
3. Abordagem de prototipagem rápida:.....	9
4. Estrutura organizacional:.....	9
5. Gestão de qualidade:.....	9
6. Ferramentas utilizadas:.....	10
3. Documentação da Execução do Projeto.....	10
3.1 Imersão.....	10
Canvas de Identificação do Domínio:.....	10
Personas:.....	10
Mapa de Empatia - Profissional de RH:.....	11
Outras Personas:.....	11
Fontes de Dados e Políticas:.....	11
Objetivos Validados na Fase de Imersão:.....	12
3.2 Ideação.....	12
Canvas de Ideação de Soluções:.....	12
Design de Prompts:.....	12
Protótipos e Wireframes:.....	13
3.3 Produção.....	13
Arquitetura do Sistema:.....	13
Frontend (Streamlit):.....	13
Backend (Python Modular):.....	14
Estrutura de Diretórios:.....	14

Fluxo de Processamento LLM:.....	14
Funcionalidades Atuais:.....	15
Autenticação.....	15
Gestão de Documentos.....	15
Chatbot IA.....	15
Interface.....	15
Link do sistema: http://localhost:8501 (execução local via Streamlit).....	15
3.4 Validação.....	15
Canvas de Escalabilidade:.....	15
Canvas de Diversificação Funcional:.....	15
4. Discussões Técnicas e Estratégicas.....	16
4.1 Escolha da API Gemini.....	16
4.2 Engenharia de Prompt.....	16
4.3 Estratégia de Desenvolvimento.....	17
4.4 Desafios Técnicos Enfrentados.....	17
5. Considerações Éticas.....	19
5.1 Riscos Identificados.....	19
5.2 Impactos Sociais Negativos Potenciais.....	19
5.3 Mitigações Implementadas.....	20
5.4 Impactos Sociais Positivos.....	20
6. Lições Aprendidas e Reflexões Finais.....	20
6.1 Validação da Abordagem Baseada em Modelos Generativos.....	21
6.2 Arquitetura Modular como Facilitador do Desenvolvimento Iterativo.....	21
6.3 Importância do Contexto Específico do Domínio.....	21
6.4 Equilíbrio entre Automação e Supervisão Humana.....	21
6.5 Desafios na Gestão de Expectativas e Adoção Organizacional.....	21
6.6 Sustentabilidade Técnica e Evolução Contínua.....	22
6.7 Contribuições Individuais da Equipe.....	22

1. Introdução

O projeto **EvolveRH** foi desenvolvido no contexto da disciplina Transformação Digital com IA, com o objetivo de criar uma solução inovadora para automatização e otimização de processos de Recursos Humanos através de Inteligência Artificial generativa. A plataforma consiste em um chatbot corporativo inteligente capaz de compreender perguntas em linguagem natural e fornecer respostas precisas baseadas nas políticas internas da empresa, alinhando-se às necessidades de transformação digital do setor de RH.

O sistema utiliza **Modelos de Linguagem de Grande Escala (LLMs)**, especificamente a família **Gemini** da Google, para processar consultas de colaboradores, contextualizar respostas com base em documentação corporativa e fornecer suporte automatizado para dúvidas frequentes sobre férias, benefícios, políticas internas e procedimentos administrativos. O EvolveRH é voltado para empresas de médio e grande porte, visando reduzir a sobrecarga operacional das equipes de RH, padronizar informações e melhorar a experiência do colaborador através de respostas rápidas e confiáveis.

1.1 Contextualização do Problema

Empresas de médio e grande porte enfrentam diariamente o desafio de responder a um alto volume de dúvidas internas relacionadas a políticas corporativas, benefícios, férias e procedimentos administrativos. Pesquisas indicam que profissionais de RH gastam aproximadamente **40%** do seu tempo (equivalente a 17 horas semanais) com tarefas burocráticas repetitivas que poderiam ser automatizadas.

Este cenário resulta em:

- Sobrecarga operacional nas equipes de RH, desviando profissionais de atividades estratégicas
- Inconsistência nas respostas devido à comunicação humana sujeita a variações
- Tempo de espera prolongado para colaboradores que buscam informações
- Dificuldade de escalabilidade nos processos de atendimento interno
- Custos operacionais elevados com suporte manual de rotina

Para os colaboradores, isso se traduz em espera desnecessária por informações básicas; para a empresa, representa ineficiência operacional e alto custo de mão de obra qualificada em tarefas de baixo valor agregado.

1.2 Objetivos do Projeto

Objetivo Geral:

Desenvolver um assistente virtual inteligente para o setor de Recursos Humanos capaz de automatizar respostas a dúvidas frequentes dos colaboradores, reduzindo a carga operacional da equipe de RH e melhorando a eficiência dos processos administrativos através de IA generativa.

Objetivos Específicos:

1. Padronizar as informações transmitidas aos colaboradores, garantindo consistência e alinhamento com políticas corporativas
2. Melhorar a experiência do colaborador através de respostas instantâneas e confiáveis, disponíveis 24/7
3. Implementar uma solução escalável que possa ser adaptada a diferentes departamentos e políticas organizacionais
4. Promover a cultura de inovação através da adoção prática de IA generativa no ambiente corporativo
5. Fornecer insights valiosos sobre as dúvidas mais frequentes para otimização contínua das políticas internas

1.3 Justificativa Tecnológica e Abordagem Metodológica

A interpretação de dúvidas em linguagem natural e a geração de respostas contextualizadas exigem compreensão semântica, manutenção de contexto e alinhamento com documentação específica, capacidades em que LLMs como a família Gemini demonstram excelente desempenho. A escolha pela API Gemini foi motivada por sua performance em compreensão de contexto corporativo, suporte multilíngue (especialmente para português brasileiro), capacidade de lidar com documentos extensos e custo-benefício favorável para implementações empresariais.

O desenvolvimento seguiu uma abordagem metodológica baseada em **Design Thinking aplicado à IA**, organizada nas seguintes etapas:

- **Fase de Imersão:**
 - Análise das principais dores dos departamentos de RH através de pesquisas setoriais
 - Mapeamento dos tipos mais frequentes de consultas internas
 - Definição das personas: colaboradores que acessam informações de RH e profissionais de RH responsáveis pelo atendimento
- **Fase de Ideação:**
 - Definição de funcionalidades essenciais do chatbot (respostas automáticas sobre férias, benefícios, políticas)
 - Design da arquitetura inicial do sistema e fluxos de interação
 - Desenvolvimento de estratégias de prompt engineering para respostas contextualizadas
- **Fase de Produção:**

- Implementação da arquitetura modular (serviços separados para IA, processamento de documentos e UI)
- Integração com API Gemini e configuração de múltiplos modelos para fallback
- Desenvolvimento da interface Streamlit com diferenciação por tipo de usuário (RH vs colaborador)
- Implementação de sistema de upload e processamento de documentos PDF
- **Fase de Validação:**
 - Testes com perguntas reais de colaboradores para ajuste de contexto e comportamento
 - Avaliação de clareza, relevância e aderência às diretrizes corporativas

Tecnologias Utilizadas:

- Backend: Python com Streamlit para interface web
- IA Generativa: Google Gemini API com sistema de fallback multi-modelo
- Processamento de Documentos: PyPDF2 para extração de texto, FPDF para geração de relatórios
- Arquitetura: Design modular com separação clara de responsabilidades (handlers para IA, PDF, UI)
- Gerenciamento de Estado: Session state do Streamlit para controle de autenticação e histórico

2. Metodologia

O desenvolvimento do EvolveRH seguiu a metodologia **AIDesign** aplicada a soluções corporativas, estruturada em quatro fases principais: Imersão, Ideação, Produção e Validação; garantindo alinhamento às necessidades reais do setor de RH, viabilidade técnica e entrega de valor em ciclos iterativos e incrementais.

2.1 Fases do Desenvolvimento

1. Imersão

Objetivo: Compreender profundamente os desafios operacionais do setor de Recursos Humanos e mapear requisitos funcionais e técnicos para automação com IA.

Atividades realizadas:

- **Pesquisa setorial:** Análise de estudos sobre carga operacional em departamentos de RH, identificando que profissionais gastam ~40% do tempo com tarefas repetitivas
- **Mapeamento de fluxos:** Documentação dos principais tipos de consultas internas (férias, benefícios, políticas, ponto eletrônico)
- **Coleta de documentação:** Reunião de manuais, políticas internas e FAQs de empresas para compor base de conhecimento inicial

- **Definição de personas:** Identificação dos perfis de usuário principais:
 1. **Colaborador:** Precisa acessar informações de RH de forma rápida e confiável
 2. **Profissional de RH:** Necessita reduzir carga operacional para focar em atividades estratégicas
- **Análise de soluções existentes:** Estudo de ferramentas de automação de RH e chatbots corporativos disponíveis no mercado

2. Ideação

Objetivo: Definir a proposta de valor, escopo do MVP e arquitetura técnica para a solução de chatbot inteligente.

Atividades realizadas:

- **Definição das funcionalidades centrais do MVP:**
 - Sistema de autenticação com perfis diferenciados (RH × Colaborador)
 - Upload e processamento de documentos PDF com políticas
 - Chatbot com respostas baseadas em IA generativa
 - Histórico de conversas e exportação para PDF
 - Dashboard com métricas de uso
- **Design da arquitetura inicial:**
 - Estrutura modular com separação de responsabilidades
 - Fluxo de interação do chatbot: pergunta → contexto → resposta
 - Integração com API de LLM e sistema de fallback
- **Elaboração inicial dos prompts para Gemini API:**
 - Template estruturado para contextualização com políticas corporativas
 - Instruções específicas para tom de voz profissional
 - Diretrizes para casos de informação não encontrada
 - Formatação padronizada de respostas
- **Avaliação de riscos técnicos:**
 - Limites de tokens e contexto dos modelos
 - Latência e disponibilidade da API
 - Consistência e alinhamento das respostas
 - Segurança e privacidade de dados corporativos

3. Produção

Objetivo: Implementar a solução funcional com arquitetura modular e integrar todos os componentes técnicos.

Atividades realizadas:

- **Implementação da arquitetura modular:**
 - Criação da estrutura `src/modules/` com separação clara:
 1. `ai_handler.py`: Integração com Gemini API
 2. `pdf_handler.py`: Processamento de documentos

- 3. `config.py`: Gerenciamento de configurações
- 4. `ui_components.py`: Componentes de interface
 - Desenvolvimento do entry point `app.py` com orquestração central
- **Integração com Google Gemini API:**
 - Configuração de múltiplos modelos para sistema de fallback
 - Implementação de algoritmo de tentativa sequencial
 - Parâmetros otimizados
- **Desenvolvimento do sistema de processamento de documentos:**
 - Integração com PyPDF2 para extração de texto
 - Implementação de persistência em arquivo com encoding UTF-8
 - Sistema de carregamento hierárquico de múltiplas fontes
- **Implementação da interface Streamlit:**
 - Design diferenciado por tipo de usuário
 - Sistema de autenticação com session state
 - Componentes reutilizáveis (header, sidebar, chat area)
 - CSS customizado para experiência profissional
- **Configuração do ambiente e dependências:**
 - Criação do `requirements.txt` com versões específicas
 - Implementação de variáveis de ambiente para API keys
 - Estrutura de diretórios para dados persistentes

4. Validação

Objetivo: Verificar a eficácia da solução em cenários reais e refinar com base em feedback contínuo.

Atividades realizadas:

- **Testes com perguntas reais:**
 - Simulação de dúvidas frequentes de colaboradores
 - Avaliação de clareza, relevância e precisão das respostas
 - Testes de borda e casos de informação não encontrada
- **Coleta de feedback qualitativo:**
 - Avaliação com profissionais de RH (persona especializada)
 - Testes com colaboradores simulados (persona leiga)
 - Análise de usabilidade e experiência do usuário
- **Otimização dos prompts:**
 - Ajustes no template para melhor contextualização
 - Refinamento das instruções para tom de voz apropriado
 - Melhoria na formatação de respostas complexas
- **Registro de métricas iniciais:**
 - Tempo médio de resposta do chatbot
 - Precisão das respostas (comparação com fonte oficial)
 - Satisfação percebida pelos usuários-teste
 - Performance no processamento de documentos PDF

2.2 Gestão do Projeto

1. Organização em marcos principais:

- Marco 1: Pesquisa e definição do problema (2 semanas)
- Marco 2: Levantamento de requisitos e design da arquitetura (1 semana)
- Marco 3: Implementação dos módulos principais (3 semanas)
- Marco 4: Integração e testes iniciais (1 semana)
- Marco 5: Refinamento e documentação (1 semana)

2. Controle de versão e colaboração:

- Uso de Git para controle de versão do código
- Repositório centralizado com branches por funcionalidade
- Commits descritivos com convenção semântica
- Revisão de código entre membros da equipe

3. Abordagem de prototipagem rápida:

- Desenvolvimento incremental com ciclos curtos (1-2 semanas)
- Feedback contínuo através de demonstrações funcionais
- Priorização baseada em valor para o usuário final
- Adaptação ágil a novos requisitos e aprendizados

4. Estrutura organizacional:

- Reuniões semanais: Revisão de progresso e planejamento
- Design Reviews: Avaliação de UI/UX e experiência do usuário
- Code Reviews: Garantia de qualidade e padrões técnicos

5. Gestão de qualidade:

- Testes manuais em cada entrega incremental
- Validação cruzada entre diferentes perfis de usuário
- Monitoramento de métricas de performance técnica
- Documentação contínua de decisões e aprendizados

6. Ferramentas utilizadas:

- Desenvolvimento: VS Code, Python 3.10+, Streamlit
- Colaboração: Git, Discord para comunicação
- Documentação: Markdown, diagramas de arquitetura

Esta abordagem metodológica garantiu não apenas o desenvolvimento técnico da solução, mas também sua aderência às necessidades reais do setor de RH, viabilidade de implementação em ambientes corporativos e preparação para escalabilidade futura, resultando em um produto que equilibra inovação tecnológica com aplicabilidade prática imediata.

3. Documentação da Execução do Projeto

Esta seção detalha a execução do EvolveRH conforme as quatro fases da metodologia AIDesign: Imersão, Ideação, Produção e Validação; apresentando artefatos, decisões técnicas e resultados obtidos.

3.1 Imersão

Canvas de Identificação do Domínio:

O projeto foi concebido para automatizar e otimizar processos de Recursos Humanos através de um assistente virtual inteligente, identificando e resolvendo a sobrecarga operacional do setor, com foco na redução de tarefas repetitivas e melhoria da experiência do colaborador.

Personas:

Nome: Ana Costa

Idade: 35 anos

Formação: Graduada em Psicologia com especialização em Gestão de Pessoas

Localização Típica: Departamento de RH de empresas médias e grandes

Perfil profissional: 8 anos de experiência em RH, responsável por atendimento interno, processos administrativos e orientação a colaboradores

Objetivo principal: Reduzir a carga operacional de tarefas repetitivas para focar em iniciativas estratégicas de desenvolvimento organizacional

Necessidade / Dor	Funcionalidade EvolveRH que atende
Responder repetidamente as mesmas perguntas sobre férias e benefícios	Chatbot com respostas automáticas baseadas em políticas
Gerenciar manualmente documentos e políticas	Sistema de upload e processamento automático de PDFs
Garantir consistência nas informações transmitidas	Base de conhecimento centralizada e padronizada
Reduzir tempo de espera dos colaboradores	Respostas instantâneas 24/7 via IA
Extrair insights sobre dúvidas frequentes	Dashboard com métricas e análise de consultas

Mapa de Empatia - Profissional de RH:

1. Vê: Alto volume de e-mails e mensagens com dúvidas repetitivas
2. Ouve: Colaboradores frustrados com demora nas respostas
3. Pensa e sente: Sobrecarga administrativa impede trabalho estratégico
4. Fala e faz: "Só hoje respondi 20 vezes a mesma pergunta sobre férias"
5. Dores: Burnout por tarefas repetitivas, falta de tempo para projetos importantes
6. Ganhos: Automação de processos, dados para tomada de decisão, reconhecimento por inovação

Outras Personas:

Colaborador Empresarial:

- Perfil: Funcionários de diferentes departamentos que precisam acessar informações de RH regularmente
- Dor principal: Demora para obter respostas claras sobre direitos e benefícios

Gestor de Departamento:

- Perfil: Líderes que precisam orientar suas equipes sobre políticas corporativas
- Dor principal: Inconsistência nas informações e tempo gasto com burocracia

Fontes de Dados e Políticas:

1. Documentos corporativos padrão: Manuais de políticas, regulamentos internos, códigos de conduta
2. Legislação trabalhista: CLT, convenções coletivas, normas regulamentadoras
3. Setores específicos: Políticas de empresas de tecnologia, varejo, serviços e indústria
4. Formatos diversos: PDFs, documentos Word, intranets, portais de RH

A seleção garante:

1. Diversidade de setores e portes empresariais
2. Abrangência de tópicos (férias, benefícios, segurança, ética)
3. Representatividade de diferentes culturas organizacionais
4. Adaptabilidade a diversos formatos documentais

Objetivos Validados na Fase de Imersão:

1. Padronizar 100% das respostas sobre políticas corporativas
2. Oferecer disponibilidade 24/7 para consultas de colaboradores
3. Criar base de conhecimento centralizada e atualizável

3.2 Ideação

Canvas de Ideação de Soluções:

A solução proposta combina IA Generativa e Processamento de Linguagem Natural para:

1. Compreender perguntas em linguagem natural dos colaboradores
2. Contextualizar respostas com base em políticas específicas da empresa
3. Fornecer interface diferenciada por perfil de usuário
4. Gerar insights sobre dúvidas frequentes e lacunas nas políticas

Design de Prompts:

Estrutura do Prompt Principal:

```
Contexto = "
Você é um assistente virtual de RH especializado em responder dúvidas de colaboradores.
Use APENAS as informações fornecidas nas políticas da empresa para responder.

POLÍTICAS DA EMPRESA:
{políticas}

HISTÓRICO DA CONVERSA (últimas 5 mensagens):
{historico_conversa}

PERGUNTA: {pergunta}

INSTRUÇÕES IMPORTANTES:
1. Responda baseado APENAS nas políticas fornecidas acima
2. Seja claro, direto e amigável
3. Se não encontrar a informação nas políticas, diga: "Não encontrei essa informação nas políticas disponíveis."
4. Formate com marcadores quando apropriado
5. Assine como "Assistente Virtual de RH"
6. Mantenha a resposta em português brasileiro e não use nenhum emoji na resposta, de forma alguma.

RESPOSTA:
""
```

Características do Prompt Engineering:

- Contextualização explícita do domínio (RH corporativo)
- Limitação estrita às políticas fornecidas
- Manutenção de contexto conversacional
- Formatação padronizada para consistência
- Fallback controlado para casos de informação ausente

Protótipos e Wireframes:

Interface Streamlit desenvolvida com:

1. Fluxo principal: Login → Dashboard → Chat → Histórico
2. Componentes modulares: Header, Sidebar, Chat Area, Document Manager
3. Design responsivo: Adaptação para desktop e mobile
4. Sistema de temas: Cores corporativas (azul para RH, verde para colaborador)


Wireframes principais:

- Tela de login com validação de credenciais
- Dashboard com métricas de uso

- Interface de chat com histórico visual
- Painel de upload de documentos (apenas RH)
- Sidebar com navegação contextual

3.3 Produção

Arquitetura do Sistema:



Frontend (Streamlit):

- Framework: Streamlit 1.32+ com componentes customizados
- Estrutura: Páginas únicas com renderização condicional
- Componentes principais:
 - `login_page()`: Autenticação com validação
 - Sistema de badges por tipo de usuário
 - Chat container com estilização CSS
 - Upload múltiplo de PDFs com progress bar
 - Dashboard com métricas em tempo real

Backend (Python Modular):

- Arquitetura: Service-oriented com handlers especializados
- Integrações:
 - Google Gemini API com fallback multi-modelo
 - PyPDF2 para processamento de documentos
 - FPDF para geração de relatórios
- Gerenciamento de estado: Session state do Streamlit

Estrutura de Diretórios:

```
evolverh-api/
├── app.py                # Entry point principal
├── requirements.txt      # Dependências do projeto
├── politicas.txt         # Base de conhecimento original
├── .env                 # Variáveis de ambiente (API keys)
├── .gitignore           # Controle de versionamento
├── src/                 # Código fonte modularizado
│   ├── __init__.py      # Inicialização do pacote
│   └── modules/         # Módulos de negócio
│       ├── __init__.py  # Exportação dos módulos
│       ├── config.py    # Configurações e credenciais
│       ├── ai_handler.py # Serviço de IA
│       ├── pdf_handler.py # Processamento de PDFs
│       └── ui_components.py # Componentes de UI
├── dados/               # Diretório gerado automaticamente
│   └── politicas_extraidas.txt # Políticas extraídas de PDFs
├── documentação/       # Arquivos de suporte
│   └── README.md        # Documentação principal
```

Fluxo de Processamento LLM:

1. Recebimento: Pergunta do usuário via chat interface
2. Contextualização: Histórico + Políticas + Prompt template
3. Processamento: Envio para Gemini API com parâmetros otimizados
4. Fallback: Tentativa sequencial em 6 modelos diferentes
5. Resposta: Formatação e exibição para o usuário
6. Persistência: Armazenamento no histórico da sessão

Funcionalidades Atuais:

Autenticação

- Login diferenciado – Credenciais para RH e colaborador

Gestão de Documentos

- Upload de PDFs – Processamento múltiplo com PyPDF2
- Extração de texto – Conversão PDF → texto estruturado
- Persistência – Salvamento em arquivo com UTF-8

Chatbot IA

- Respostas contextualizadas – Baseadas em políticas carregadas
- Histórico de conversa – Manutenção de contexto (últimas 5 mensagens)
- Fallback inteligente – 6 modelos Gemini + resposta simulada

Interface

- Dashboard métricas – Estatísticas de uso em tempo real
- Exportação PDF – Geração de relatório da conversa
- Navegação contextual – Sidebar com opções por tipo de usuário

Link do sistema: <https://evolverrh.streamlit.app/>

3.4 Validação

Canvas de Escalabilidade:

1. Expansão para múltiplos departamentos: Além de RH, suporte a TI, Financeiro, Jurídico
2. Integração com sistemas corporativos: Conexão com SAP, Oracle, sistemas de ponto
3. Suporte multilíngue: Expansão para inglês e espanhol para empresas multinacionais
4. Análise preditiva: Identificação de tendências em dúvidas e lacunas políticas

Canvas de Diversificação Funcional:

1. Dashboard analítico avançado: Métricas de satisfação, tópicos mais consultados
2. Sistema de tickets integrado: Escalonamento automático para casos complexos
3. Treinamento contínuo do modelo: Fine-tuning com dados específicos da empresa
4. API externa: Disponibilização do chatbot para integração em outros sistemas
5. Relatórios customizados: Exportação em múltiplos formatos (PDF, Excel, JSON)

Roadmap Funcional:

Funcionalidades atuais: Chatbot com IA generativa (Implementado, prioridade alta), Upload/processamento de PDFs (Implementado, prioridade alta), Autenticação diferenciada (Implementado, prioridade alta) e Dashboard de métricas (Implementado, prioridade média).

Funcionalidades planejadas: Integração com sistemas de RH (Em desenvolvimento, prioridade alta), Análise de sentimentos (Planejado, prioridade média), Suporte multilíngue (Planejado, prioridade baixa), API externa (Planejado, prioridade média) e Mobile app (Longo prazo, prioridade baixa).

4. Discussões Técnicas e Estratégicas

4.1 Escolha da API Gemini

A escolha pela API Gemini foi motivada pelo seu desempenho superior em compreensão contextual, suporte robusto para a língua portuguesa e custo-benefício favorável para

implementações corporativas. Quando comparada a outras soluções disponíveis no mercado, a API Gemini demonstrou maior consistência em respostas baseadas em documentação específica, característica essencial para um sistema que deve operar rigorosamente dentro das políticas internas da empresa. A decisão foi fundamentada nos seguintes aspectos principais:

- Suporte multilíngue de qualidade, com desempenho otimizado para português brasileiro, reduzindo ambiguidades e interpretações errôneas de termos técnicos do domínio de recursos humanos.
- Arquitetura multi-modelo que permite um sistema de fallback hierárquico, garantindo resiliência operacional mesmo em cenários de indisponibilidade pontual de modelos específicos.
- Estrutura de custos previsível e escalável, adequada para implementações empresariais que podem variar em volume de requisições.
- Capacidade de processamento de contexto extenso, permitindo a incorporação de políticas complexas e histórico de conversa sem degradação significativa de performance.

A configuração implementada utiliza seis modelos Gemini em ordem de preferência, começando pelo 'models/gemini-2.0-flash' como principal, com fallback automático para modelos alternativos em caso de falha, garantindo disponibilidade contínua do serviço.

4.2 Engenharia de Prompt

A eficácia do sistema depende fundamentalmente da estruturação cuidadosa dos prompts enviados à API Gemini. A estratégia de prompt engineering adotada foi desenvolvida através de iterações sucessivas, visando maximizar a precisão e relevância das respostas dentro do contexto corporativo de recursos humanos.

O prompt principal foi estruturado em três componentes essenciais: contexto do domínio, conteúdo das políticas empresariais e histórico conversacional recente. O contexto define explicitamente o papel do assistente como especialista em RH, estabelece restrições rigorosas sobre o uso exclusivo das políticas fornecidas e especifica o formato desejado para as respostas. As políticas empresariais são inseridas dinamicamente, garantindo que o modelo opere sempre com a versão mais atualizada da documentação. O histórico das últimas cinco interações é incluído para manter coerência conversacional, permitindo referências a perguntas e respostas anteriores.

As instruções incorporadas no prompt incluem a exigência de basear respostas apenas nas políticas fornecidas, a determinação de um tom profissional mais amigável, a formatação com marcadores para informações estruturadas, e o tratamento específico para casos onde a informação solicitada não está presente nas políticas disponíveis. Esta última instrução é particularmente crítica, prevenindo a geração de informações inventadas ou especulativas pelo modelo.

4.3 Estratégia de Desenvolvimento

A estratégia de desenvolvimento foi orientada pelo princípio de entrega incremental de valor, com foco na construção de um produto mínimo viável funcional dentro dos prazos estabelecidos. A arquitetura modular foi concebida para permitir desenvolvimento paralelo dos diferentes componentes do sistema, com interfaces bem definidas entre os módulos.

A escolha tecnológica recaiu sobre Python e Streamlit devido à combinação de produtividade no desenvolvimento, robustez para aplicações de IA e adequação ao perfil técnico da equipe. Streamlit ofereceu a vantagem de permitir a criação de interfaces web interativas com complexidade mínima, acelerando significativamente o ciclo de desenvolvimento do frontend. Python, por sua vez, forneceu acesso a uma ecologia madura de bibliotecas para processamento de linguagem natural, manipulação de documentos e integração com APIs de IA.

A organização do código em módulos especializados — separando lógica de IA, processamento de documentos, componentes de interface e configuração — seguiu princípios de design de software estabelecidos, em particular o princípio da responsabilidade única. Esta abordagem facilitou testes unitários, reuso de componentes e manutenção evolutiva. A decisão de implementar autenticação baseada em session state do Streamlit, embora simplificada nesta versão, foi tomada considerando os requisitos de prototipagem, com clara identificação da necessidade de evolução para um sistema de autenticação empresarial em versões futuras.

O processo de desenvolvimento adotou práticas de integração contínua, com repositório Git estruturado em branches de funcionalidade, revisões de código sistemáticas e documentação técnica atualizada em paralelo com a implementação.

4.4 Desafios Técnicos Enfrentados

Durante o desenvolvimento do EvolveRH, diversos desafios técnicos significativos foram identificados e abordados através de soluções específicas.

Processamento de documentos PDF heterogêneos: A variabilidade na estrutura e qualidade dos documentos PDF corporativos representou um desafio substancial. Documentos com layout complexo, elementos gráficos ou formatação não padrão exigiam técnicas de extração adaptativas. A solução implementada baseou-se na combinação de PyPDF2 para extração básica com heurísticas de pós-processamento para limpeza e estruturação do texto. Para casos particularmente complexos, foi implementado um sistema de logging detalhado que permite identificar documentos problemáticos para processamento manual ou ajuste das políticas de extração.

Gestão de contexto em conversas extensas: Limitações de token dos modelos de linguagem impõem restrições práticas sobre a quantidade de contexto histórico que pode ser incluído em cada requisição. A estratégia adotada seleciona seletivamente as últimas cinco interações, priorizando a manutenção do fluxo conversacional recente enquanto mantém o

foco na pergunta atual. Esta abordagem representa um equilíbrio calculado entre custo computacional, latência e coerência conversacional.

Consistência e alinhamento das respostas: Garantir que o assistente virtual opere estritamente dentro dos limites das políticas corporativas, evitando extrapolações ou interpretações não autorizadas, exigiu ajustes iterativos nos prompts e parâmetros do modelo. A temperatura foi configurada em 0.3 para reduzir a criatividade do modelo em favor da fidelidade às fontes, e as instruções foram reforçadas com exemplos negativos explicitando comportamentos indesejados.

Desempenho em cenários de informação incompleta: Quando questionado sobre tópicos não cobertos pelas políticas carregadas, o modelo inicialmente tendia a gerar respostas plausíveis mas não fundamentadas. A solução envolveu a implementação de um sistema de fallback em dois níveis: primeiro, instruções explícitas no prompt para reconhecer limitações de conhecimento; segundo, uma função de resposta simulada baseada em palavras-chave que fornece respostas genéricas apropriadas quando a API principal não pode fornecer uma resposta fundamentada.

Integração de múltiplas fontes de políticas: Empresas frequentemente possuem políticas distribuídas em múltiplos documentos e formatos. O sistema desenvolvido implementa um carregador hierárquico que agrega conteúdo de fontes primárias (arquivo político.txt principal), documentos PDF processados e conteúdo carregado durante a sessão atual. Esta abordagem proporciona flexibilidade operacional, mas introduz complexidade na garantia de consistência e resolução de conflitos entre fontes, desafio parcialmente mitigado através da manutenção de metadados de proveniência para cada informação.

Cada um destes desafios foi abordado através de soluções técnicas específicas, documentadas no código e nos artefatos de projeto, formando um corpus de conhecimento que informará as futuras iterações do sistema.

5. Considerações Éticas

5.1 Riscos Identificados

- 1. Interpretação incorreta de políticas corporativas**
A IA pode falhar ao interpretar nuances ou exceções contidas em políticas internas, especialmente quando estas são redigidas com linguagem ambígua ou possuem múltiplas interpretações possíveis.
- 2. Inconsistência na aplicação de regras**
A variabilidade inerente aos modelos generativos pode levar a respostas inconsistentes para perguntas similares, gerando confusão entre os colaboradores e potenciais inequidades no tratamento de informações.
- 3. Falha na identificação de requisitos legais específicos**
O sistema pode não detectar quando uma pergunta envolve obrigações legais trabalhistas que exigem consulta a especialistas, particularmente em casos complexos ou com jurisprudência recente.

4. Viés na formulação das respostas
Modelos treinados em conjuntos de dados predominantemente em inglês podem apresentar desempenho inferior em português, especialmente com termos técnicos específicos do direito trabalhista brasileiro.
5. Superficialidade na análise de casos complexos
Perguntas que envolvam múltiplas variáveis ou situações particulares podem receber respostas genéricas que não contemplam a complexidade do caso real.
6. Dependência excessiva da automação
Colaboradores e profissionais de RH podem passar a confiar cegamente nas respostas automatizadas, negligenciando a análise crítica e a consulta a especialistas quando necessário.

5.2 Impactos Sociais Negativos Potenciais

1. Decisões profissionais baseadas em informações incompletas
Colaboradores podem tomar decisões sobre direitos trabalhistas baseados apenas nas respostas do assistente virtual, sem buscar orientação jurídica adequada para situações complexas.
2. Erosão do papel estratégico dos profissionais de RH
A automação excessiva pode levar à desvalorização da expertise humana em recursos humanos, reduzindo oportunidades de aconselhamento personalizado e desenvolvimento organizacional.
3. Amplificação de desigualdades informacionais
Colaboradores com menor familiaridade tecnológica podem ser excluídos dos benefícios do sistema ou interpretar incorretamente as respostas recebidas.
4. Privatização do conhecimento corporativo
A centralização do conhecimento em sistemas de IA pode criar barreiras ao compartilhamento informal e à aprendizagem coletiva dentro da organização.

5.3 Mitigações Implementadas

1. Transparência sobre limitações do sistema
O sistema inclui declarações explícitas sobre sua natureza assistiva, enfatizando que não substitui a consulta a profissionais qualificados para questões complexas ou com implicações legais significativas.
2. Mecanismos de escalonamento humano
A arquitetura permite a integração futura com sistemas de tickets ou encaminhamento para especialistas, garantindo que questões complexas possam ser redirecionadas apropriadamente.
3. Validação periódica das respostas
Estabelecimento de processos para revisão amostral das interações por profissionais de RH, permitindo ajustes contínuos nos prompts e na base de conhecimento.
4. Registro e auditoria das interações
Todas as conversas são registradas e podem ser auditadas, facilitando a identificação de padrões problemáticos e a correção proativa de informações imprecisas.

5. Controle de acesso diferenciado

Sistema de autenticação que distingue claramente entre profissionais de RH e colaboradores, permitindo diferentes níveis de responsabilidade no uso e gestão do sistema.

5.4 Impactos Sociais Positivos

1. Democratização do acesso a informações de RH
Colaboradores em todas as posições hierárquicas e localizações geográficas passam a ter acesso imediato a informações consistentes sobre políticas corporativas.
2. Redução da carga administrativa
Liberação de tempo dos profissionais de RH para atividades de maior valor estratégico, como desenvolvimento organizacional, planejamento de carreira e iniciativas de bem-estar.
3. Padronização e equidade na comunicação
Redução de inconsistências na transmissão de informações, garantindo que todos os colaboradores recebam orientações alinhadas e atualizadas.
4. Documentação e transparência organizacional
Criação de registro estruturado das dúvidas e necessidades informacionais dos colaboradores, informando melhorias contínuas nas políticas e comunicações internas.
5. Capacitação digital do setor de RH
Introdução de práticas de transformação digital que atualizam as competências dos profissionais de recursos humanos para o contexto tecnológico contemporâneo.

6. Lições Aprendidas e Reflexões Finais

O desenvolvimento do EvolveRH proporcionou aprendizados significativos sobre a implementação de soluções de IA generativa em contextos corporativos reais, destacando tanto oportunidades quanto limitações desta abordagem tecnológica.

6.1 Validação da Abordagem Baseada em Modelos Generativos

A opção por utilizar modelos de linguagem de grande escala em vez de sistemas baseados em regras rígidas mostrou-se acertada, especialmente considerando a variabilidade natural das perguntas em linguagem natural. Esta abordagem permitiu maior flexibilidade na interpretação de consultas, mas demandou investimento significativo em engenharia de prompts para garantir alinhamento estrito com as políticas corporativas. A lição central foi equilibrar a flexibilidade interpretativa do modelo com a necessidade de precisão e consistência nas respostas.

6.2 Arquitetura Modular como Facilitador do Desenvolvimento Iterativo

A decisão de implementar uma arquitetura modular demonstrou valor crescente ao longo do desenvolvimento. Esta abordagem permitiu ajustes independentes em componentes específicos sem impactar o sistema como um todo, facilitando a iteração rápida baseada em feedback dos usuários. A separação clara entre processamento de documentos, lógica de IA e interface provou-se particularmente útil durante os ciclos de teste e refinamento.

6.3 Importância do Contexto Específico do Domínio

A eficácia do sistema dependeu criticamente da qualidade e especificidade do contexto fornecido ao modelo generativo. Políticas genéricas ou redigidas de forma vaga resultaram em respostas menos precisas, enquanto documentos detalhados e bem estruturados permitiram respostas de alta qualidade. Esta observação reforça que o valor da IA generativa em contextos corporativos está intrinsecamente ligado à qualidade dos dados e conhecimentos de domínio incorporados ao sistema.

6.4 Equilíbrio entre Automação e Supervisão Humana

O projeto evidenciou que sistemas de IA generativa em ambientes corporativos funcionam melhor como assistentes inteligentes que amplificam a capacidade humana, não como substitutos completos da expertise profissional. As interações mais bem-sucedidas ocorreram quando o sistema lidava com consultas factuais bem documentadas, enquanto questões complexas ou com nuances exigiam claramente intervenção humana. Esta distinção orientou o design da experiência do usuário e a definição de escopo do sistema.

6.5 Desafios na Gestão de Expectativas e Adoção Organizacional

O desenvolvimento técnico mostrou-se apenas uma parte do desafio, sendo igualmente importante gerenciar expectativas sobre capacidades e limitações do sistema. A comunicação clara sobre o que o sistema pode e não pode fazer, juntamente com treinamento adequado dos usuários finais, revelou-se crucial para a adoção efetiva. Esta lição tem implicações significativas para estratégias de implementação em ambientes organizacionais reais.

6.6 Sustentabilidade Técnica e Evolução Contínua

A manutenção da qualidade das respostas ao longo do tempo exigirá atualização contínua tanto da base de conhecimento quanto dos prompts, particularmente diante de mudanças nas políticas corporativas ou na legislação trabalhista. Esta necessidade de evolução contínua destacou a importância de estabelecer processos sustentáveis para gestão do ciclo de vida do sistema, incluindo monitoramento de performance, coleta de feedback estruturado e mecanismos para incorporação de novos conhecimentos.

6.7 Contribuições Individuais da Equipe

O desenvolvimento do EvolveRH foi possibilitado pela integração de competências complementares e pelo trabalho colaborativo de cada membro da equipe, cujas contribuições específicas foram fundamentais para a concepção, implementação e validação da solução.

Cauê Marinho (Desenvolvedor): Responsável pelo sistema de processamento de documentos PDF e pela lógica de extração e persistência de políticas. Desenvolveu a funcionalidade de upload múltiplo, a extração de texto com PyPDF2 e a consolidação das fontes de conhecimento em uma base unificada, criando a fundação de dados que alimenta o sistema de IA.

Jorge Freitas (Desenvolvedor): Responsável pela arquitetura técnica central do sistema, pela integração robusta com a API Gemini e pela implementação do mecanismo de fallback multi-modelo. Desenvolveu ainda o módulo de cadastro e autenticação, garantindo a estrutura de perfis diferenciados e a confiabilidade técnica da aplicação.

Maria Beatriz (PMO e Desenvolvedora): Coordenou o planejamento e a execução do projeto, gerenciando prazos, requisitos e a comunicação entre todos os membros da equipe. Na parte de desenvolvimento, contribuiu decisivamente para a modularização do código, o setup inicial do ambiente e o refinamento iterativo dos prompts, assegurando a qualidade das respostas geradas pela IA.

Karen Verçosa (Designer - UX): Concebeu a experiência do usuário e a interface visual da aplicação, com atenção especial à diferenciação clara entre os perfis de RH e colaborador. Garantiu a usabilidade, acessibilidade e coerência visual de todos os componentes. Além disso, criou diversos documentos PDF de teste utilizados durante o desenvolvimento para validar o sistema de processamento e extração.

A sinergia entre essas competências: gestão de projeto, arquitetura de software, processamento de dados e design de experiência foi o elemento catalisador que transformou o conceito do EvolveRH em uma solução funcional, robusta e alinhada com as necessidades reais do setor de recursos humanos.

7. Referências

Github: <https://github.com/jorgelcfff/evolverh-api>

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em:

https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/L13709.htm.

UNIÃO EUROPEIA. Regulamento (UE) 2016/679 do Parlamento Europeu e do Conselho, de 27 de abril de 2016. Regulamento Geral sobre a Proteção de Dados (GDPR). Disponível em: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>.

GOOGLE. Documentação da API Gemini. Disponível em: <https://ai.google.dev/>.

AIDESIGN. Metodologia AIDesign: guia de aplicação prática. Recife: CESAR School, 2024.

COCKBURN, S. C4 Model: visualising software architecture. Disponível em: <https://c4model.com/>.

8. Apêndice

IA Generativa – Tipo de inteligência artificial capaz de criar conteúdo novo, como texto, com base em padrões aprendidos de dados existentes. No contexto do EvolveRH, refere-se à capacidade do sistema de gerar respostas textuais contextualizadas sobre políticas de recursos humanos a partir de consultas em linguagem natural.

LLM (Large Language Model) – Modelo de linguagem de grande escala treinado em extensos conjuntos de dados textuais, capaz de compreender, interpretar e gerar linguagem humana. No projeto, os modelos da família Gemini atuam como núcleo cognitivo do assistente virtual, processando perguntas e produzindo respostas alinhadas às políticas corporativas.

Gemini API – Interface de programação de aplicações fornecida pela Google para acesso a seus modelos de linguagem generativa. No EvolveRH, a API é integrada com um sistema de fallback que utiliza seis modelos diferentes de forma hierárquica para garantir disponibilidade e confiabilidade das respostas.

Engenharia de Prompt – Técnica de otimização e estruturação de instruções enviadas a modelos de linguagem para eliciar respostas mais precisas, consistentes e contextualmente apropriadas. No projeto, envolveu a criação de templates específicos que definem o papel do assistente, as fontes de informação autorizadas e o formato desejado das respostas.

Políticas Corporativas – Conjunto de regras, diretrizes e procedimentos estabelecidos por uma organização para regular suas operações e o comportamento de seus colaboradores. No EvolveRH, constituem a base de conhecimento primária a partir da qual o assistente virtual deriva suas respostas.

Sistema de Fallback Multi-modelo – Arquitetura de resiliência que implementa uma sequência hierárquica de modelos de linguagem alternativos para garantir a continuidade do serviço quando o modelo primário apresenta falhas ou indisponibilidade. O sistema tenta até seis modelos Gemini diferentes antes de recorrer a respostas simuladas baseadas em palavras-chave.

PyPDF2 – Biblioteca Python para manipulação de arquivos PDF, utilizada no projeto para extrair conteúdo textual de documentos de políticas corporativas. Permite o processamento de múltiplos arquivos, a extração estruturada por páginas e a conversão para formato texto processável pelos modelos de linguagem.

Session State (Streamlit) – Mecanismo de gerenciamento de estado da biblioteca Streamlit que permite manter dados persistentes durante a sessão do usuário. No EvolveRH, é utilizado para controlar autenticação, histórico de conversas, documentos carregados e preferências de interface entre diferentes interações.

Dashboard de Métricas de RH – Painel visual que apresenta indicadores quantitativos sobre o uso do sistema, incluindo número de mensagens trocadas, perguntas mais frequentes, tempo médio de resposta e volume de documentos processados. Fornece insights para otimização contínua do serviço.

Arquitetura Modular – Padrão de design de software que organiza o sistema em componentes independentes com responsabilidades bem definidas e interfaces claras entre eles. No EvolveRH, manifesta-se na separação entre processamento de IA, manipulação de documentos, componentes de interface e configuração, facilitando manutenção e evolução.

AIDesign – Metodologia de desenvolvimento de soluções de inteligência artificial estruturada em quatro fases cíclicas: Imersão (compreensão do problema), Ideação (proposta de solução), Produção (implementação) e Validação (testes e refinamento). Foi adotada como framework para o desenvolvimento iterativo do projeto.

Streamlit – Framework Python para criação rápida de aplicações web interativas para machine learning e ciência de dados. No projeto, foi escolhido por sua produtividade no desenvolvimento de interfaces, capacidade de integração com bibliotecas de IA e suporte nativo a componentes interativos.

FPDF – Biblioteca Python para geração de documentos PDF, utilizada no EvolveRH para criar relatórios exportáveis das conversas entre usuários e o assistente virtual. Permite a formatação estruturada com cabeçalhos, parágrafos e preservação do histórico completo.

UTF-8 – Padrão de codificação de caracteres que suporta todos os caracteres do conjunto Unicode, incluindo acentos e caracteres especiais do português. No sistema, é utilizado para garantir a correta preservação e exibição de textos extraídos de documentos e gerados pelo assistente.

Base de Conhecimento Corporativa – Repositório estruturado de informações organizacionais que inclui políticas, procedimentos, regulamentos e diretrizes internas. No contexto do projeto, refere-se ao conjunto consolidado de documentos processados que alimentam o sistema de respostas do assistente virtual.